Análisis del Comportamiento de Compras de Clientes

1. Descripción del Proyecto

Este proyecto analiza el comportamiento de compras de clientes utilizando datos transaccionales de 3.900 compras en diversas categorías de productos. El objetivo es descubrir insights sobre patrones de gasto, segmentos de clientes, preferencias de productos y comportamiento de suscripción para orientar decisiones estratégicas del negocio.

2. Resumen del Dataset

- Filas: 3.900
- Columnas: 18
- Características principales:
  - Datos demográficos del cliente (Edad, Género, Ubicación, Estado de Suscripción)
  - Detalles de compra (Artículo comprado, Categoría, Monto de compra, Temporada, Talla, Color)
  - Comportamiento de compra (Descuento aplicado, Código promocional, Compras anteriores, Frecuencia de compras, Calificación de reseña, Tipo de envío)
- Datos faltantes: 37 valores en la columna de Calificación de Reseña

3. Análisis Exploratorio de Datos con Python

Comenzamos con la preparación y limpieza de datos en Python:

- **Carga de Datos:** Importación del dataset utilizando pandas.
- **Exploración Inicial:** Uso de df.info() para verificar la estructura y .describe() para estadísticas descriptivas.

	Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discou Appli
count	3900.000000	3900.000000	3900	3900	3900	3900.000000	3900	3900	3900	3900	3863.000000	3900	3900	39
unique	NaN	NaN	2	25	4	NaN	50	4	25	4	NaN	2	6	
top	NaN	NaN	Male	Blouse	Clothing	NaN	Montana	M	Olive	Spring	NaN	No	Free Shipping	
freq	NaN	NaN	2652	171	1737	NaN	96	1755	177	999	NaN	2847	675	22
mean	1950.500000	44.068462	NaN	NaN	NaN	59.764359	NaN	NaN	NaN	NaN	3.750065	NaN	NaN	N
std	1125.977353	15.207589	NaN	NaN	NaN	23.685392	NaN	NaN	NaN	NaN	0.716983	NaN	NaN	N
min	1.000000	18.000000	NaN	NaN	NaN	20.000000	NaN	NaN	NaN	NaN	2.500000	NaN	NaN	N
25%	975.750000	31.000000	NaN	NaN	NaN	39.000000	NaN	NaN	NaN	NaN	3.100000	NaN	NaN	N
50%	1950.500000	44.000000	NaN	NaN	NaN	60.000000	NaN	NaN	NaN	NaN	3.800000	NaN	NaN	N
75%	2925.250000	57.000000	NaN	NaN	NaN	81.000000	NaN	NaN	NaN	NaN	4.400000	NaN	NaN	N
max	3900.000000	70.000000	NaN	NaN	NaN	100.000000	NaN	NaN	NaN	NaN	5.000000	NaN	NaN	N

Discount Applied	Promo Code Used	Previous Purchases	Payment Method	Frequency of Purchases
3900	3900	3900.000000	3900	3900
2	2	NaN	6	7
No	No	NaN	PayPal	Every 3 Months
2223	2223	NaN	677	584
NaN	NaN	25.351538	NaN	NaN
NaN	NaN	14.447125	NaN	NaN
NaN	NaN	1.000000	NaN	NaN
NaN	NaN	13.000000	NaN	NaN
NaN	NaN	25.000000	NaN	NaN
NaN	NaN	38.000000	NaN	NaN
NaN	NaN	50.000000	NaN	NaN

- **Manejo de Datos Faltantes:** Se verificaron los valores nulos y se imputaron los valores faltantes en la columna **Review Rating** utilizando la calificación mediana de cada categoría de producto.
- **Estandarización de Columnas:** Se renombraron las columnas a **snake case** para mayor legibilidad y documentación.
- **Ingeniería de Características:** Se creó la columna **age_group** agrupando las edades de los clientes, y la columna **purchase_frequency_days** a partir de los datos de compra.
- **Verificación de Consistencia:** Se verificó si **discount_applied** y **promo_code_used** eran redundantes; se eliminó **promo_code_used.**
- **Integración con Base de Datos:** Se conectó el script de Python a PostgreSQL y se cargó el DataFrame limpio en la base de datos para el análisis con SQL.

4. Análisis de Datos con SQL (Transacciones Comerciales)

Se realizó un análisis estructurado en PostgreSQL para responder preguntas clave del negocio:

1. Ingresos Totales por Género

Se compararon los ingresos totales generados por clientes masculinos y femeninos.

```
SELECT gender AS genero,
       SUM(purchase_amount) AS Ingresos
FROM customer
GROUP BY gender;
```

Resultado:

	genero text	ingresos numeric
1	Female	75191
2	Male	157890

2. Usuarios con Descuento que Gastan por Encima del Promedio

Se identificaron los clientes que usaron descuentos, pero aun así gastaron por encima del monto promedio de compra.

```
SELECT customer_id, age, gender, category, purchase_amount
FROM customer
WHERE discount_applied = 'Yes'
  AND purchase_amount > (SELECT AVG(purchase_amount) FROM customer);
```

Resultado:

	customer_id bigint	age bigint	gender text	category text	purchase_amount bigint
1	2	19	Male	Clothing	64
2	3	50	Male	Clothing	73
3	4	21	Male	Footwear	90
4	7	63	Male	Clothing	85
5	9	26	Male	Outerwear	97
6	12	30	Male	Clothing	68
7	13	61	Male	Outerwear	72
8	16	64	Male	Clothing	81
9	20	66	Male	Clothing	90
10	22	31	Male	Clothing	62
11	24	31	Male	Clothing	88
12	29	54	Male	Accessori...	94
13	32	33	Male	Clothing	70

Total rows: 839 | Query complete 00:00:00.127 | Rows selected: 839

La consulta retornó 839 clientes que aplicaron descuentos y aun así superaron el monto promedio de compra ($59,76 USD).

3. Top 5 Productos con Mayor Calificación Promedio

Se encontraron los productos con las calificaciones promedio de reseña más altas.

```
SELECT item_purchased AS item_comprado,
       ROUND(AVG(review_rating::numeric), 2) AS promedio_review
FROM customer
GROUP BY item_purchased
ORDER BY promedio_review DESC
LIMIT 5;
```

Resultado:

	item_comprado text	promedio_review numeric
1	Gloves	3.86
2	Sandals	3.84
3	Boots	3.82
4	Hat	3.80
5	Skirt	3.78

4. Comparación por Tipo de Envío: Standard vs Express

Se compararon los montos promedio de compra entre los envíos Standard y Express.

```
SELECT shipping_type AS "Tipo de Envío",
       ROUND(AVG(purchase_amount::numeric), 2) AS "Monto Promedio"
FROM customer
WHERE shipping_type = 'Express' OR shipping_type = 'Standard'
GROUP BY shipping_type
ORDER BY AVG(purchase_amount::numeric) DESC;
```

Resultado:

	Tipo de Compra text	Monto Promedio de Compra numeric
1	Express	60.48
2	Standard	58.46

Total rows: 2 | Query complete 00:00:00.089

5. Suscriptores vs. No Suscriptores

Se comparó el gasto promedio y los ingresos totales entre suscriptores y no suscriptores.

```
SELECT COUNT(customer_id)                AS "Total Clientes",
       subscription_status               AS "Estado Suscripción",
       SUM(purchase_amount)              AS "Ingreso Total",
       ROUND(AVG(purchase_amount::numeric), 2) AS "Promedio de Compra"
FROM customer
GROUP BY subscription_status;
```

Resultado:

	Total Clientes bigint	Clientes Suscriptos text	Ingreso total numeric	Promedio de Compra numeric
1	2847	No	170436	59.87
2	1053	Yes	62645	59.49

Total rows: 2 | Query complete 00:00:00.063

6. Productos con Mayor Dependencia de Descuentos

Se identificaron los 5 productos con el mayor porcentaje de compras realizadas con descuentos aplicados.

```
SELECT item_purchased,
       ROUND((SUM(CASE WHEN discount_applied = 'Yes'
                  THEN 1.0 ELSE 0.0 END) / COUNT(*)) * 100, 2)
       AS proporcion_descuento
FROM customer
GROUP BY item_purchased
ORDER BY proporcion_descuento DESC
LIMIT 5;
```

Resultado:

	item_purchased text	proporcion_descuento numeric
1	Hat	50.00
2	Sneakers	49.66
3	Coat	49.07
4	Sweater	48.17
5	Pants	47.37

Total rows: 5 | Query complete 00:00:00.064

7. Segmentación de Clientes

Se clasificaron los clientes en segmentos Nuevo, Frecuente y Leal según su historial de compras previas.

```
WITH customer_type AS (
  SELECT customer_id, previous_purchases,
    CASE
      WHEN previous_purchases = 1       THEN 'Nuevo'
      WHEN previous_purchases BETWEEN 2 AND 10 THEN 'Frecuente'
      ELSE 'Leal'
    END AS customer_segment
  FROM customer
)
SELECT customer_segment,
       COUNT(*) AS "Número de Clientes"
FROM customer_type
GROUP BY customer_segment;
```

Resultado:

	customer_segment text	Numero de Clientes bigint
1	Frecuente	701
2	Leal	3116
3	Nuevo	83

Total rows: 3 | Query complete 00:00:00.056

8. Top 3 Productos Más Comprados por Categoría

Se listaron los productos más comprados dentro de cada categoría de productos.

```
WITH item_counts AS (
  SELECT category, item_purchased,
         COUNT(customer_id) AS total_orders,
         SUM(purchase_amount) AS total_revenue,
         ROW_NUMBER() OVER (
           PARTITION BY category
           ORDER BY COUNT(customer_id) DESC
         ) AS item_rank
  FROM customer
  GROUP BY category, item_purchased
)
SELECT item_rank, category, item_purchased,
       total_orders, total_revenue
FROM item_counts
WHERE item_rank <= 3;
```

Resultado:

	item_rank bigint	category text	item_purchased text	total_orders bigint	total_revenue numeric
1	1	Accessories	Jewelry	171	10010
2	2	Accessories	Sunglasses	161	9649
3	3	Accessories	Belt	161	9635
4	1	Clothing	Blouse	171	10410
5	2	Clothing	Pants	171	10090
6	3	Clothing	Shirt	169	10332
7	1	Footwear	Sandals	160	9200
8	2	Footwear	Shoes	150	9240
9	3	Footwear	Sneakers	145	8635
10	1	Outerwear	Jacket	163	9249
11	2	Outerwear	Coat	161	9275

Total rows: 11 | Query complete 00:00:00.099 | Rows selected: 11

9. Compradores Frecuentes y Suscripciones

Se verificó si los clientes con más de 5 compras previas tienen mayor tendencia a suscribirse.

```
SELECT subscription_status,
       COUNT(customer_id) AS repeat_buyers
FROM customer
WHERE previous_purchases > 5
GROUP BY subscription_status;
```

Resultado:

	subscription_status text	repeat_buyers bigint
1	No	2518
2	Yes	958

Total rows: 2 | Query complete 00:00:00.080

10. Ingresos por Grupo Etario

Se calculó la contribución total de ingresos de cada grupo etario.

```
SELECT age_group,
       SUM(purchase_amount) AS "Total Ingresos"
FROM customer
GROUP BY age_group
ORDER BY SUM(purchase_amount) DESC;
```

Resultado:

	age_group text	Total Ingresos numeric
1	Young Adult	62143
2	Middle-aged	59197
3	Adult	55978
4	Senior	55763

Total rows: 4 | Query complete 00:00:00.064

5. Dashboard en Power BI

Finalmente, se construyó un dashboard interactivo en Power BI para presentar los insights de forma visual. El dashboard incluyó los siguientes elementos:

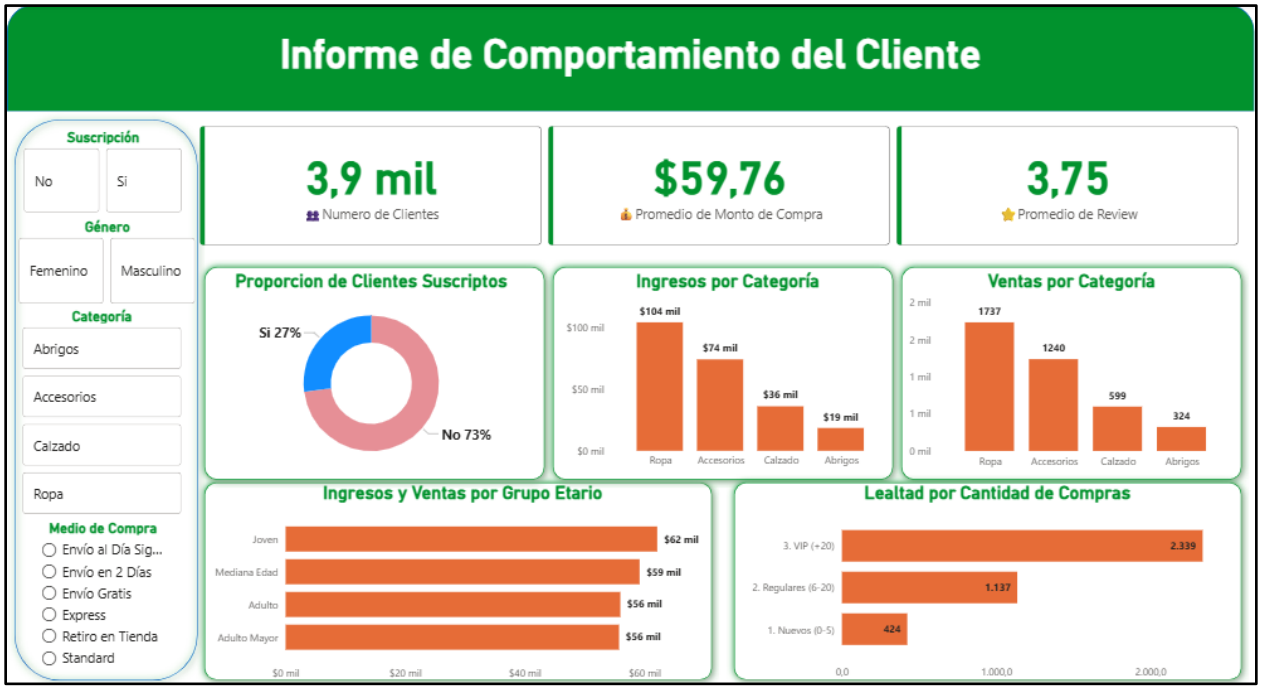

- **KPIs principales:** Número total de clientes (3.900), Monto promedio de compra ($59,76) y Calificación promedio de reseña (3,75).
- **Filtros interactivos:** por Estado de Suscripción, Género, Categoría y Tipo de Envío.
- **Gráfico de torta:** Porcentaje de clientes por estado de suscripción (Sí: 27%, No: 73%).
- **Gráficos de barras:** Ingresos por Categoría, Ventas por Categoría, Ingresos por Grupo Etario y Ventas por Grupo Etario.

6. Recomendaciones de Negocio

- **Impulsar las Suscripciones:** Aunque los suscriptores representan solo el 27% de los clientes, el gasto promedio es similar al de los no suscriptores. Se recomienda promover beneficios exclusivos para atraer más suscriptores y aumentar el valor de vida del cliente.
- **Programas de Fidelización y Segmentos VIP:** El gráfico de Lealtad por Cantidad de Compras revela que 2.339 clientes son VIP (≥20 compras previas), representando la mayoría de la base. Se recomienda crear un programa de beneficios exclusivos para este segmento (descuentos anticipados, envío prioritario gratuito) para garantizar su retención. A su vez, diseñar campañas de activación para los 424 clientes Nuevos (0-5 compras) con el objetivo de convertirlos en Regulares.

- **Revisión de la Política de Descuentos:** Productos como el Sombrero (50%) y las Zapatillas (49,66%) tienen alta dependencia de descuentos. Se recomienda equilibrar el impulso de ventas con el control de márgenes para estos artículos.
- **Posicionamiento de Productos:** Destacar en campañas los productos mejor calificados (Guantes, Sandalias, Botas) y los más vendidos por categoría para maximizar el impacto del marketing.
- **Marketing Segmentado por Edad y Medio de Envío:** El grupo Joven lidera los ingresos con $62mil, seguido de Mediana Edad ($59mil). Se recomienda enfocar campañas digitales en estos segmentos. Adicionalmente, los usuarios de envío Express presentan un ticket promedio superior ($60,48), por lo que incluir opciones de envío rápido en las comunicaciones puede incrementar el valor por transacción.
- **Estrategia de Género:** Los clientes masculinos generan más del doble de ingresos que los femeninos ($157.890 vs $75.191). Se recomienda analizar las razones y diseñar campañas específicas para incrementar la participación femenina.